

EXPOSÉ
Leonhard Lüdeke

Architekturentwicklung und Threat Modelling eines Multi-Agenten-Systems

FAKULTÄT INFORMATIK UND DIGITALE GESELLSCHAFT

Faculty of Computer Science and Digital Society

Betreuung durch: Prof. Dr. Thomas, Lehmann
Eingereicht am: 17. Juni, 2026

HOCHSCHULE FÜR ANGEWANDTE
WISSENSCHAFTEN HAMBURG
Hamburg University of Applied Sciences

Inhaltsverzeichnis

1 Ausgangslage	2
Literatur	3

Keywords: KI-Agenten, Multi-Agent-Systeme, Threats

1 Ausgangslage

Large-Language-Model-Anwendungen entwickeln sich zunehmend von einfachen Chatbots hin zu agentischen Systemen, in denen mehrere spezialisierte Komponenten kooperieren, Werkzeuge aufrufen und Teilaufgaben arbeitsteilig bearbeiten. In der Forschung und in industriellen Frameworks wird dieser Übergang häufig als Entwicklung hin zu agentischer KI beziehungsweise zu LLM-basierten Multi-Agenten-Systemen beschrieben, wobei klassische Konzepte der Multi-Agenten-Forschung mit generativer KI neu interpretiert werden. Für Unternehmen ist dieser Ansatz attraktiv, weil spezialisierte Agenten Aufgaben wie Informationsbeschaffung, Klassifikation, Dokumentenanalyse oder domänenspezifische Assistenz modular abbilden können. [1]

Mit dem funktionalen Potenzial steigt jedoch auch die Komplexität des Systems. Während klassische Multi-Agenten-Systeme bereits Fragen der Koordination, Kommunikation und Vertrauensbildung adressieren, bringen LLM-basierte Agenten zusätzliche Risiken mit sich, darunter Prompt Injection, Tool Misuse, ungewollte Datenweitergabe, unsichere Kontextübernahme und intransparente Entscheidungslogiken. Neuere Arbeiten zu agentischen Workflows zeigen, dass sich Angriffe in solchen Systemen nicht nur auf einzelne Komponenten richten, sondern über Promptketten, Werkzeuge und Agentenkommunikation kaskadieren können. [4, 2, 5]

Im Kontext von Unternehmen gewinnt diese Betrachtungsweise besondere Relevanz. Ein erster Prototyp eines MAS, welcher in ein bestehendes Unternehmensökosystem eingebettet werden soll ist teil dieser Arbeit. Hierbei ist eine Anbindung an OpenWebUI [3] als zentrale Nutzungsoberfläche vorgesehen und ein Betrieb unter annähernd realen Infrastrukturbedingungen wie internen Netzen, HTTP-basierten Service-Schnittstellen, möglichen Kubernetes-Betriebsmodellen sowie der Wahl zwischen On-Prem- und Off-Prem-LLMs betrachtet werden. Gleichzeitig wird für den Aufbau eines Threat-Modells angenommen, dass alle berechtigten Nutzerinnen und Nutzer Zugriff auf die Oberfläche haben und ein Angreifer sich bereits innerhalb des Intranets mit regulären Rechten befinden kann. Diese Annahme verschiebt den Fokus weg von rein perimeterorientierter Sicherheit hin zu Identitäts-, Autorisierungs-, Kommunikations- und Segmentierungskontrollen innerhalb des Systems. [4] Wie tief einzelne Aspekte beachtet werden, wird sich im Laufe der Arbeit herausstellen.

Vor diesem Hintergrund genügt es nicht, eine funktionierende Multi-Agenten-Architektur isoliert zu entwerfen. Vielmehr müssen Anforderungsanalyse, Sicherheitsannahmen und Threat Modelling direkten Einfluss auf Architekturentscheidungen haben. Die Architektur eines Multi-Agenten-Systems ist in diesem Sinne nicht nur technische Struktur, sondern Ausdruck priorisierter Qualitätsziele, Sicherheitsanforderungen und Risikobehandlungen. Besonders relevant ist dabei der Orchestrator, da er die Eingaben der Nutzer verarbeitet, Agenten auswählt, Kommunikationsflüsse steuert und damit maßgeblich die Sicherheits- und Qualitätscharakteristika des Gesamtsystems bestimmt.

Literatur

- [1] BOTTI, V.: *Agentic AI and Multiagentic: Are We Reinventing the Wheel?*. – URL <https://arxiv.org/abs/2506.01463>. – Zugriffsdatum: 2026-06-17. – Version Number: 1
- [2] FERRAG, Mohamed A. ; TIHANYI, Norbert ; HAMOUDA, Djallel ; MAGLARAS, Leandros ; LAKAS, Abderrahmane ; DEBBAH, Merouane: From Prompt Injections to Protocol Exploits: Threats in LLM-Powered AI Agents Workflows. 12, Nr. 2, S. 353–383. – URL <http://arxiv.org/abs/2506.23260>. – Zugriffsdatum: 2026-06-17. – ISSN 24059595
- [3] OPEN WEBUI, Inc: *Official website of Open WebUI, Inc.* – URL <https://openwebui.com/>
- [4] OWASP: *OWASP Threat Modeling Project*. – URL <https://owasp.org/www-project-threat-modeling/>
- [5] TETE, Stephen B.: *Threat Modelling and Risk Analysis for Large Language Model (LLM)-Powered Applications*. – URL <http://arxiv.org/abs/2406.11007>. – Zugriffsdatum: 2026-06-17