

EXPOSÉ
Leonhard Lüdeke

Architekturentwicklung und Threat Modelling eines Multi-Agenten-Systems

FAKULTÄT INFORMATIK UND DIGITALE GESELLSCHAFT

Faculty of Computer Science and Digital Society

Betreuung durch: Prof. Dr. Thomas, Lehmann
Eingereicht am: 17. Juni, 2026

HOCHSCHULE FÜR ANGEWANDTE
WISSENSCHAFTEN HAMBURG
Hamburg University of Applied Sciences

Inhaltsverzeichnis

1	Kontext und Zielsetzung	1
1.1	Arbeitstitel	1
1.2	Ausgangslage und Motivation	1
1.3	Problemstellung	2
1.4	Zielsetzung der Arbeit	2
1.5	Forschungsfragen	3
2	Grundlagen und Bewertungsrahmen	4
2.1	Theoretische und fachliche Grundlagen	4
2.2	Agentische KI und Multi-Agenten-Systeme	4
2.3	Agentenkommunikation und Interoperabilität	5
2.4	Threat Modeling für LLM-basierte Agentensysteme	6
3	Architektur	7
	Literatur	7

Keywords: KI-Agenten, Multi-Agent-Systeme, Threats

1 Kontext und Zielsetzung

1.1 Arbeitstitel

Konzeption, sicherheitsorientierte Architekturentwicklung und Threat Modelling eines LLM-basierten Multi-Agenten-Systems im Unternehmenskontext.

1.2 Ausgangslage und Motivation

Große Sprachmodelle werden im aktuellen Diskurs zunehmend nicht mehr nur als Grundlage einfacher dialogorientierter Anwendungen verstanden, sondern als Bausteine agensischer Systeme, in denen mehrere spezialisierte Komponenten Aufgaben übernehmen, Informationen austauschen und arbeitsteilig zur Bearbeitung komplexerer Probleme beitragen. [21, 8, 5]

Diese Entwicklung lässt sich als Fortführung klassischer Konzepte aus der Multi-Agenten-Forschung und Verteilten Systemen interpretieren, die durch LLM-basierte Sprachverarbeitung, flexible Werkzeugnutzung und dynamische Kontextverarbeitung erweitert werden. [8, 24, 19] Mit dieser funktionalen Erweiterung steigt zugleich die technische und organisatorische Komplexität. [8, 20, 7]

Während klassische Multi-Agenten-Systeme bereits Fragen der Koordination, Kooperation und Kommunikation adressieren, entstehen bei LLM-basierten Architekturen zusätzliche Unsicherheiten durch probabilistische Modellentscheidungen, die Einbindung externer Tools und die Verarbeitung heterogener Kontextquellen. [20, 7, 14]

Für Unternehmen ist daher nicht nur relevant, ob ein Multi-Agenten-System grundsätzlich leistungsfähig erscheint, sondern ob es unter realen Randbedingungen nachvollziehbar, beherrschbar und sicher betrieben werden kann. [14, 7]

Damit gewinnt die Fragestellung wie LLM Basierte Multi-Agenten-Systeme in bestehende technische und organisatorische Strukturen eingebettet werden können, immer mehr an Relevanz. Somit rücken Architekturentscheidungen in den Mittelpunkt, die nicht allein funktional, sondern zugleich unter Sicherheits-, Betriebs- und Governance-Gesichtspunkten begründet werden müssen. [20, 11]

1.3 Problemstellung

In aktuellen Diskussionen zu agentischen Systemen stehen häufig Funktionsumfang, Automatisierungspotenziale und die Qualität generierter Ergebnisse im Vordergrund. [11, 7, 25]

Weniger systematisch behandelt wird dagegen die Frage, wie ein solches System im Unternehmenskontext so entworfen werden kann, dass Sicherheitsaspekte nicht erst nachträglich ergänzt, sondern bereits auf Architekturebene berücksichtigt werden. [18, 20, 7]

Gerade bei LLM Basierten Multi-Agenten-Systemen erweitert sich die Angriffsfläche gegenüber einfacheren Einzelagenten- oder Chatbot-Ansätzen deutlich. [20, 7, 3]

Risiken ergeben sich nicht nur aus direkten Benutzereingaben, sondern auch aus Agentenkommunikation, Delegationsmechanismen, Tool-Aufrufen, Retrieval-Prozessen, Protokollschichten und der Weitergabe von Kontexten oder Zwischenergebnissen. [20, 11, 7, 4, 25] Daraus folgt, dass eine rein funktionale Betrachtung des Systementwurfs für die vorliegende Problemstellung nicht ausreicht. [20, 18]

Die zentrale Problemstellung der Arbeit besteht daher darin, eine nachvollziehbare Verbindung zwischen funktionaler Architekturentwicklung und systematischem Threat Modeling herzustellen. Untersucht wird, wie sich ein LLM-basiertes Multi-Agenten-System so konzipieren lässt, dass sowohl fachliche Anforderungen als auch Schutzbedarfe, Vertrauensgrenzen und Gegenmaßnahmen konsistent in einer Zielarchitektur abgebildet werden können. [11, 7]

1.4 Zielsetzung der Arbeit

Ziel der Arbeit ist die Konzeption eines LLM-basierten Multi-Agenten-Systems einen Unternehmenskontext, sowie die sicherheitsorientierte Bewertung dieses Entwurfs mithilfe eines strukturierten Threat Modelings. Im Vordergrund steht damit nicht primär die vollständige produktive Implementierung, sondern die Entwicklung einer fachlich plausiblen, technisch realisierbaren und sicherheitsorientierten begründeten Zielarchitektur.

Die Arbeit verfolgt dabei drei miteinander verbundene Teilziele. Erstens soll eine Architektur entwickelt werden, in der Rollen, Komponenten, Schnittstellen und Kommunikationsbeziehungen klar beschrieben sind. Zweitens sollen relevante Bedrohungen systematisch identifiziert und entlang von Komponenten, Datenflüssen und Vertrauensgrenzen analysiert werden. Drittens sollen daraus konkrete Maßnahmen abgeleitet werden, die zeigen, wie Sicherheitsanforderungen in ein konsistentes Systemdesign überführt werden können. [13, 20, 11]

1.5 Forschungsfragen

Die übergeordnete Forschungsfrage lautet:

Wie kann ein LLM-basiertes Multi-Agenten-System im Unternehmenskontext so konzipiert werden, dass funktionale und nicht funktionale Anforderungen, technische Realisierbarkeit und sicherheitsorientiertes Threat Modeling in einer konsistenten Architektur zusammengeführt werden?

Zur Beantwortung dieser Leitfrage werden folgende untergeordnete Forschungsfragen betrachtet:

- Welche funktionalen und nicht-funktionalen Anforderungen prägen die Zielarchitektur eines solchen Systems?
- Welche Komponenten, Kommunikationsbeziehungen und Vertrauensgrenzen ergeben sich aus dem gewählten Multi-Agenten-Ansatz?
- Welche Bedrohungen entstehen durch Benutzerinteraktion, Agentenkommunikation, Tool-Nutzung und Modellanbindung?
- Mit welchen architektonischen und organisatorischen Maßnahmen lassen sich diese Bedrohungen angemessen mindern?

- In welchen Punkten erzeugt der Multi-Agenten-Ansatz einen Mehrwert gegenüber einfacheren Architekturalternativen, und welche zusätzliche Komplexität entsteht dadurch?

2 Grundlagen und Bewertungsrahmen

2.1 Theoretische und fachliche Grundlagen

Die theoretische Grundlage der Arbeit verbindet klassische Konzepte der Multi-Agenten-Forschung mit neueren Ansätzen LLM-basierter agentischer Systeme. [21, 8, 15] Ausgangspunkt ist der in der Literatur etablierte Agentenbegriff, nach dem ein Agent als in einer Umgebung situierte Softwareeinheit verstanden werden kann, die flexibel und autonom im Sinne ihrer Entwurfsziele handelt. [21, 22, 15]

Auf dieser Basis lässt sich ein Multi-Agenten-System als eine Architektur beschreiben, in der mehrere autonome oder teilautonome Einheiten kooperieren, kommunizieren und ihre Aktivitäten koordinieren, um individuelle oder gemeinsame Ziele zu verfolgen. [8, 12, 15, 5]

Damit sind heutige LLM-basierte Agentensysteme als Erweiterung klassischer Agenten- und MAS-Konzepte zu verstehen, bei denen Sprachmodelle neue Fähigkeiten der Interaktion, Werkzeugnutzung und Kontextverarbeitung bereitstellen, ohne die grundlegenden Fragen nach Autonomie, Koordination und Verantwortungsverteilung obsolet zu machen. [5, 24, 8, 15]

Diese Veränderung der Agentensysteme hin zu LLM-basierten Agentensystemen lassen neue Angriffsvektoren entstehen [18, 11], die neben den klassischen Bedrohungen für Multi-Agenten-Systemen bestehen [20]

Dazu gehören insbesondere Trust Boundaries, kontrollierte Schnittstellen, das Prinzip minimaler Rechte sowie Kriterien zur Beurteilung von Robustheit, Nachvollziehbarkeit und Beherrschbarkeit komplexer agentischer Systeme. [20, 18]

2.2 Agentische KI und Multi-Agenten-Systeme

Agentische KI bezeichnet Systeme, die nicht nur einzelne Antworten erzeugen, sondern zielgerichtet Aufgaben bearbeiten, Zwischenschritte planen, externe Werkzeuge verwenden und Teile ihres Handlungsablaufs selbst steuern. [21, 9]

Von einem Multi-Agenten-System wird gesprochen, wenn mehrere spezialisierte Agenten miteinander interagieren und durch Kommunikation, Delegation oder Orchestrierung zu einem Gesamtergebnis beitragen.[8, 22, 15]

Für die Arbeit ist es wichtig, zwischen dem traditionellen Agentenbegriff und heutigen LLM-basierten Agenten zu unterscheiden. [15, 5]

Die Grundlage, welche Aspekte bei der praktischen Entwicklung von Agenten und Multi-Agenten-Systeme betrachtet werden müssen, hat sich nicht maßgeblich verändert. Das zeigen auch die 3 relevantesten Teilaspekte [15, 8] die moderne Frameworks wie Lang-Graph, AutoGen, ADK, CrewAI und viele weitere adressieren: - Begründung (Reasoning): Wie wird das Handeln eines Agenten argumentiert. - Speicher (Memory): Entscheidungen müssen in einen Kontext gesetzt werden können und bauen sich auf (episodischer Aufbau). - Nutzung von Tools (Tool use): Ansprechen von externen Systemen (Server, API's, Browser) mittels strukturierte Eingabeaufforderungen.

Im Jahre 1996 hat sich Sycara mit der Entwicklung eines Multi-Agenten Framework namens "Retsina"beschäftigt das diese Kernelemente von Multi-Agenten-Systeme abdeckte. [17]

Jedoch beruhen Klassische Agentensysteme typischerweise stärker auf expliziten Zustandsmodellen, Regeln und formalen Interaktionsmustern, während LLM-basierte Agenten in hohem Maß durch Prompts, Kontextfenster und probabilistische Generierung geprägt sind. [21, 8, 5] Dabei setzen sich die einzelnen Agenten eigenständig ziele und Interpretieren diese in Natürlicher Sprache. Daraus entstehen neue Freiheitsgrade, aber auch neue Unsicherheiten in Bezug auf Robustheit, Fehlverhalten und Interpretierbarkeit. [19, 14]

Ein Multi-Agenten-Ansatz ist deshalb nicht per se vorteilhaft. [8, 24, 10] Sein Einsatz muss über konkrete Anforderungen wie Spezialisierung, Modularisierung, Trennung von Verantwortlichkeiten oder kontrollierte Delegation begründet werden. [8, 21, 23] Andernfalls droht zusätzliche Komplexität ohne klaren funktionalen oder sicherheitlichen Mehrwert. [20, 24, 10, 14]

2.3 Agentenkommunikation und Interoperabilität

Kommunikation ist ein zentrales Strukturmerkmal von Multi-Agenten-Systemen. [15, 6, 8]

Bereits in der klassischen Literatur wird deutlich, dass die Leistungsfähigkeit verteilter Agentensysteme wesentlich davon abhängt, wie Informationen zwischen beteiligten Einheiten ausgetauscht, interpretiert und in koordiniertes Handeln überführt werden. [8, 15, 5]

Historische Arbeiten zu KQML und spätere Standardisierungsbestrebungen, etwa im Umfeld von FIPA (Foundation for Intelligent Physical Agents), verdeutlichen, dass Agentenkommunikation nicht nur als technischer Nachrichtentransport, sondern als strukturierte Interaktion mit syntaktischen, semantischen und pragmatischen Ebenen verstanden werden sollte. [6, 2, 5]

Für LLM-basierte Multi-Agenten-Systeme bleibt diese Einsicht zentral. [19, 24]

Zwar erfolgen Kommunikationsprozesse heute häufig über natürlichsprachliche oder halb strukturierte Kontexte. Dies bietet eine gewisse Flexibilität erhöht, jedoch die Gefahr von Missverständnissen, Kontextverlusten und unkontrollierten Seiteneffekten. [24, 7]

Interoperabilität bedeutet deshalb in der vorliegenden Arbeit nicht nur technische Anschlussfähigkeit, sondern eine verlässlich kontrollierbare Zusammenarbeit trotz unterschiedlicher Rollen, Zustände und Systemgrenzen. [2, 6, 3]

2.4 Threat Modeling für LLM-basierte Agentensysteme

Threat Modeling bezeichnet wiederholbare systematische Verfahren zur Identifikation, Strukturierung und Bewertung potenzieller Bedrohungen innerhalb eines Systems. [13, 16]

Dabei umfasst das Threat Modeling diverse Frameworks und Methoden wie STRIDE, PASTA, LINDDUN, 'attack trees', 'abuse cases' und viele mehr. [13]

Auch für LLM-basierte Agentensysteme sind diese Ansatz geeignet, weil Risiken nicht nur aus einzelnen Komponenten, sondern aus Interaktionsketten zwischen Benutzenden, Agenten, Protokollen, Tools, Datenquellen und externen Diensten entstehen. [11]

Im Unterschied zu einer rein Komponenten bezogenen Sicherheitsbetrachtung erlauben Threat Modeling Framework eine methodische Analyse entlang konkreter Datenflüsse, Rollen und Vertrauensgrenzen. [16, 13, 20]

Dadurch können sowohl klassische Bedrohungen verteilter Agentensysteme als auch neuere LLM-spezifische Risiken erfasst werden. [11, 1]

Dazu zählen etwa Prompt Injection, manipulierte Kontextquellen, fehlerhafte oder überprivilegierte Tool-Aufrufe, unsichere Delegation, Protokollschwächen und unkontrollierte Weitergabe sensibler Informationen. [7? , 25, 11]

3 Architektur

Literatur

- [1] : *Threat Modelin Process (Historical)* - OWASP. – URL https://owasp.org/www-community/Threat_Modeling_Process
- [2] : *Welcome to the Foundation for Intelligent Physical Agents*. – URL <https://www.fipa.org/>. – Zugriffsdatum: 2026-07-03
- [3] ANBIAEE, Zeynab ; RABBANI, Mahdi ; MIRANI, Mansur ; PIYA, Gunjan ; OPU-SHNYEV, Igor ; GHORBANI, Ali ; DADKHAH, Sajjad: *Security Threat Modeling for Emerging AI-Agent Protocols: A Comparative Analysis of MCP, A2A, Agora, and ANP*. – URL <https://arxiv.org/abs/2602.11327>. – Zugriffsdatum: 2026-07-01. – Version Number: 2
- [4] ANDRIC, Sandro: *(PDF) LLM Hijacking: When Models Manipulate Their Routers*. – URL https://www.researchgate.net/publication/398334488_LLM_Hijacking_When_Models_Manipulate_Their_Routers. – Zugriffsdatum: 2026-07-01
- [5] BOTTI, V.: *Agentic AI and Multiagentic: Are We Reinventing the Wheel?*. – URL <https://arxiv.org/abs/2506.01463>. – Zugriffsdatum: 2026-06-17. – Version Number: 1

- [6] CHALUPSKY, Hans ; FININ, Tim ; FRITZSON, Rich ; MCKAY, Don ; SHAPIRO, Stuart ; WIEDERHOLD, Gio: An Overview of KQML: A Knowledge Query and Manipulation Language.
- [7] FERRAG, Mohamed A. ; TIHANYI, Norbert ; HAMOUDA, Djallel ; MAGLARAS, Leandros ; LAKAS, Abderrahmane ; DEBBAH, Merouane: From Prompt Injections to Protocol Exploits: Threats in LLM-Powered AI Agents Workflows. 12, Nr. 2, S. 353–383. – URL <http://arxiv.org/abs/2506.23260>. – Zugriffsdatum: 2026-06-17. – ISSN 24059595
- [8] JENNINGS, Nicholas R. ; SYCARA, Katia ; WOOLDRIDGE, Michael: A Roadmap of Agent Research and Development. 1, Nr. 1, S. 7–38. – URL <https://link.springer.com/10.1023/A:1010090405266>. – Zugriffsdatum: 2026-06-19. – ISSN 1387-2532, 1573-7454
- [9] JENNINGS, Nick R.: Commitments and conventions: The foundation of coordination in multi-agent systems. 8, Nr. 3, S. 223–250. – URL https://www.cambridge.org/core/product/identifier/S0269888900000205/type/journal_article. – Zugriffsdatum: 2026-06-30. – ISSN 0269-8889, 1469-8005
- [10] KHAN, Muhammad S. ; KHAN, Muhammad J. ; SHARIF, Muhammad ; YASMIN, Sadaf: Beyond Single-Framework Architectures: A Systematic Evaluation and Hybrid Design for Scalable Multi-Agent Coordination. 14, S. 59688–59705. – URL <https://ieeexplore.ieee.org/document/11481053/>. – Zugriffsdatum: 2026-05-22. – ISSN 2169-3536
- [11] KRAWIECKA, Klaudia ; WITT, Christian S. de: *Extending the OWASP Multi-Agent System Threat Modeling Guide: Insights from Multi-Agent Security Research*. – URL <https://arxiv.org/abs/2508.09815>. – Zugriffsdatum: 2026-07-01. – Version Number: 1
- [12] LESSER, V.R.: A retrospective view of FA/C distributed problem solving. 21, Nr. 6, S. 1347–1362. – URL <http://ieeexplore.ieee.org/document/135681/>. – Zugriffsdatum: 2026-06-22. – ISSN 00189472
- [13] OWASP: *OWASP Threat Modeling Project*. – URL <https://owasp.org/www-project-threat-modeling/>

- [14] RAZA, Shaina ; SAPKOTA, Ranjan ; KARKEE, Manoj ; EMMANOUILIDIS, Christos: TRiSM for Agentic AI: A review of Trust, Risk, and Security Management in LLM-based Agentic Multi-Agent Systems. 7, S. 71–95. – URL <https://linkinghub.elsevier.com/retrieve/pii/S2666651026000069>. – Zugriffsdatum: 2026-06-30. – ISSN 26666510
- [15] RUSSELL, Stuart J. ; NORVIG, Peter: *Artificial intelligence: a modern approach*. Fourth edition, global edition. Pearson (Prentice Hall series in artificial intelligence). – ISBN 978-1-292-40113-3 978-1-292-40117-1
- [16] SHOSTACK, Adam: *Threat modeling: Designing for security*. John wiley & sons, 2014
- [17] SYCARA, K. ; PANNU, A. ; WILLAMSON, M. ; DAJUN ZENG ; DECKER, K.: Distributed intelligent agents. 11, Nr. 6, S. 36–46. – URL <http://ieeexplore.ieee.org/document/546581/>. – Zugriffsdatum: 2026-07-01. – ISSN 0885-9000
- [18] TETE, Stephen B.: *Threat Modelling and Risk Analysis for Large Language Model (LLM)-Powered Applications*. – URL <http://arxiv.org/abs/2406.11007>. – Zugriffsdatum: 2026-06-17
- [19] WANG, Yuntao ; PAN, Yanghe ; SU, Zhou ; DENG, Yi ; ZHAO, Quan ; DU, Linkang ; LUAN, Tom H. ; KANG, Jiawen ; NIYATO, Dusit: Large Model-Based Agents: State-of-the-Art, Cooperation Paradigms, Security and Privacy, and Future Trends. 28, S. 1906–1949. – URL <https://ieeexplore.ieee.org/document/11022699/>. – Zugriffsdatum: 2026-06-30. – ISSN 1553-877X, 2373-745X
- [20] WONG, H. C. ; SYCARA, Katia: Adding security and trust to multiagent systems. 14, Nr. 9, S. 927–941. – URL <http://www.tandfonline.com/doi/abs/10.1080/08839510050144886>. – Zugriffsdatum: 2026-07-01. – ISSN 0883-9514, 1087-6545
- [21] WOOLDRIDGE, Michael ; JENNINGS, Nicholas R.: Intelligent agents: theory and practice. 10, Nr. 2, S. 115–152. – URL https://www.cambridge.org/core/product/identifier/S0269888900008122/type/journal_article. – Zugriffsdatum: 2026-06-22. – ISSN 0269-8889, 1469-8005
- [22] WOOLDRIDGE, Michael J.: *An introduction to multiagent systems*. J. Wiley. – ISBN 978-0-471-49691-5

- [23] XUE, Liwei ; LIU, Guo-Ping ; HU, Wenshan: All-in-One Framework for Design, Simulation, and Practical Implementation of Distributed Multiagent Control Systems. 54, Nr. 7, S. 4331–4344. – URL <https://ieeexplore.ieee.org/document/10493161/>. – Zugriffsdatum: 2026-06-30. – ISSN 2168-2216, 2168-2232
- [24] YAN, Bingyu ; ZHOU, Zhibo ; ZHANG, Litian ; ZHANG, Lian ; ZHOU, Ziyi ; MIAO, Dezhuang ; LI, Zhoujun ; LI, Chaozhuo ; ZHANG, Xiaoming: *Beyond Self-Talk: A Communication-Centric Survey of LLM-Based Multi-Agent Systems*. – URL <https://arxiv.org/abs/2502.14321>. – Zugriffsdatum: 2026-06-30. – Version Number: 3
- [25] ZHANG, Haiyue ; NIAN, Yi ; ZHAO, Yue: *Agent Audit: A Security Analysis System for LLM Agent Applications*. – URL <https://arxiv.org/abs/2603.22853>. – Zugriffsdatum: 2026-07-01. – Version Number: 1